Неструктурирани бази на податоци Компаративна анализа на

Релациони и Граф-базиранани

бази на податоци

Марија Вецовска

185008

Вовед

Целта на овој проект е да се направи компаративна анализа на две бази на податоци од различен тип – неструктурирана и релациона. Анализата се состои од извршување на прашалници врз истите податоци во двете бази и споредба на брзината на извршување.

Податочното множество e Identifying Influential Bloggers: Techcrunch и е преземено од Kaggle. Множеството е достапно на линкот: https://www.kaggle.com/datasets/lakritidis/identifying-influential-bloggers-techcrunch.

Неструктурирана база на податоци која се користи во рамките на овој проект е Граф-базираната база на податоци Neo4j, а релациона ваза е базата PostgreSQL.

Податочно множество:

Множеството Identifying Influential Bloggers: Techcrunch се состои од 3 фајлови:

- authors.csv податоци за 107 блогери на Techcrunch,
- posts.csv податоци за 19464 блог постови на Techcrunch напишани од авторите,
- comments.csv коментари од 746561 читатели на постовите
- inlinks.csv податоци за 193808 страници кои ги линкуваат Techcrunch постовите.

Чистење на податоците

Во рамки на податоците се среќаваат многу нецелосни податоци, исти редови со различно ИД и други грешки. Од тие причини csv фајловите се трансформираат со помош на python скрипта:

- authors_transformed.csv: ги содржи сите автори на Блогови, Постови и Коментари (автори од authors.csv, posts.csv и comments.csv).
- posts_transformed.csv: ги содржи податоците за Блогови и страници кои ги линкуваат (постови од authors.csv и inlinks.csv).
- comments_transformed.csv: ги содржи податоците за коментари од корисници (коментари од comments.csv).
- inlinks transformed.csv: ги содржи линковите меѓу сите постови(линкови од inlinks.csv)


На крај се добиваат следните csv:

```
Authors:
['name', 'meibi', 'avg_words_post', 'techcrunch_blogger']
['Jason Kincaid', '43', '4.257910', 'true']
Authors count:196273
Posts:
['url', 'title', 'content', 'author_name', 'num_comments', 'date', 'techcrunch_post']
['http://techcrunch.com/2018/84/81/we-just-tested-twitters-anywhere-platform-screenshots/', 'We Just Tested Twitter's @anywhere Platform (Screenshots)', 'During his keynote
Posts count:178395
Comments:
['id', 'post_url', 'content', 'author_name', 'date']
['id', 'post_url', 'content', 'author_name', 'date']
['il', 'http://techcrunch.com/2018/84/81/we-just-tested-twitters-anywhere-platform-screenshots/', 'Seemed to work fine.', 'BJ Cook', '2018-84-81']
Comments count:741276
Inlinks:
['post', 'linked_post']
['http://feeds.notaniche.com/-r/Afrison/-5/hXARXfINteM/', 'http://techcrunch.com/2005/86/11/technorati-new-improved/']
Inlinks count:193584
```

Внесување на податоците во PostgreSQL

- Креирање на табели и Шемата на базата на податоци:

```
create table Authors (
    name varchar primary key,
    meibi integer,
    {\tt avg\_words\_post} \  \, {\color{red}{\bf float}},
    techcrunch_blogger boolean not null
);
create table Posts (
    url varchar primary key,
    title varchar,
    content varchar,
    author_name varchar,
    comments_number integer,
    techcrunch_post boolean not null,
    date date,
    foreign key(author_name) references Authors(name)
);
create table Comments (
    id integer,
    post_url varchar,
    author_name varchar,
    content varchar,
    date varchar,
    foreign key(post_url) references Posts(url),
    foreign key(author_name) references Authors(name),
    primary key(id)
);
create table Inlinks (
    post_url varchar,
    linked_post_url varchar,
    primary key(post_url, linked_post_url),
    foreign key(post_url) references Posts(url),
    foreign key(linked_post_url) references Posts(url)
```



Внесување на податоците

о Автори

о Постови

```
Query History

1    COPY posts(url, title, content, author_name, comments_number, date, techcrunch_post)
2    FROM 'C:/Users/marija/Documents/Neo4j/relate-data/dbmss/dbms-535955cc-1561-4ae6-ac9d-cb27f2726a0e/import/posts_transformed.csv'
3    DELIMITER ','
4    CSV HEADER;

Data Output    Messages    Notifications

COPY 170305

Query returned successfully in 8 secs 483 msec.
```

Коментари

```
Query Plistory

1 COPY comments(id, post_url, content, author_name, date)
FROM 'C:/Users/marija/Documents/Neo4j/relate-data/dbmss/dbms-535955cc-1561-4ae6-ac9d-cb27f2726a0e/import/comments_transformed.csv'
3 DELIMITER ','
CSV HEADER;

Data Output Messages Notifications

COPY 741276

Query returned successfully in 48 secs 96 msec.
```

о Линкови

```
Query Plistory

1 COPY inlinks(post_url, linked_post_url)
FROM 'C:/Users/marija/Documents/Neo4j/relate-data/dbmss/dbms-535955cc-1561-4ae6-ac9d-cb27f2726a0e/import/inlinks_transformed.csv'
DELIMITER ','
CSV HEADER;


Data Output Messages Notifications

COPY 193564
Query returned successfully in 16 secs 460 msec.
```


Вкупно време на внесување во база: 75,05 секунди

Внесување на податоците во Neo4j


- Шема на базата:



- Подесување на ресурси достапни за базата



- Ограничувања



- Автори

```
:auto LOAD CSV WITH HEADERS FROM "file:///authors_transformed.csv" AS row
 2
   CALL {
3
        WITH row
4
        MERGE(a:Author{name:row.name})
 5
        SET a.meibi=toInteger(row.meibi)
 6
        SET a.avg_words_post=toFloat(row.avg_words_post)
 7
        SET a.techcrunch_blogger=toBoolean(row.techcrunch_blogger)
 8
      IN TRANSACTIONS
      Added 196273 labels, created 196273 nodes, set 392760 properties, completed after 16115 ms.
>_
Code
 Added 196273 labels, created 196273 nodes, set 392760 properties, completed after 16115 ms.
```

- Постови



- Релацијата :wrote која означува кој е авторот на кој пост

- Релацијата :commented која претставува коментар од еден автор на некој пост

```
1 :auto LOAD CSV WITH HEADERS FROM "file:///comments_transformed.csv" AS row

2 CALL {
3 WITH row
4 MATCH(p:Post{url:row.post_url})
5 MATCH(a:Author{name:row.author_name})
6 MERGE(a)-[c:commented{id:row.id, date:row.date}]→(p) SET c.content = row.comment

7 } IN TRANSACTIONS

Set 1482552 properties, created 741276 relationships, completed after 63114 ms.
```

- Релацијата :links која означува линк од еден пост према друг



Додавање на дополнителни лабели:

```
1 MATCH (a:Author{techcrunch_blogger:true})
 2 SET a:Blogger
 3 RETURN a
            a
ķ
Graph
                 "identity": 46964,
                 "labels": [
                   "Author",
                   "Blogger"
                 ],
                 "properties": {
                   "avg_words_post": 4.25791,
                   "meibi": 43,
                   "name": "Jason Kincaid",
                   "techcrunch_blogger": true
                 "elementId": "46964"
 Added 107 labels, started streaming 107 records after 3 ms and completed after 391 ms.
```

```
1 MATCH (p:Post{techcrunch_post:true})
2 SET p:Blog
3 RETURN p
ķ
           p
                "identity": 243237,
                "labels": [
                  "Post",
                  "Blog"
>_
                ],
                "properties": {
                  "date": "2010-04-01",
                  "title": "We Just Tested Twitter's @anywhere Platform (Screenshots)",
                  "techcrunch_post": true,
                  "url": "http://techcrunch.com/2010/04/01/we-just-tested-twitters-anywhere-platform-screen
                  "content": "During his keynote at SXSW last month, Twitter CEO Evan Wiliams announced an
              looks like we've just come across the first site to feature @anywhere. Meet Eggboiling
              8#8216;Connect With Twitter8#8217;; buttons to follow twitter users @jack, @biz, and @ev; a to
              each of the 8#8216;follow8#8217; buttons appropriately changed the status from 8#8220;Follow;
                        shad be Tribber (but before image/legent light bere legent) Terme /legent light agreem
 Added 19458 labels, started streaming 19458 records after 3 ms and completed after 70 ms, displaying first 1000 rows.
```


Прашалници:

1. Сите techrunch блогови кои се напишани помеѓу 2009 и 2010 година и во насловот содржат 'twitter'

Neo4j:



PostgreSQL:



Разлика: 54 ms.

2. Постовите напишани од автор кои содржат линк кон пост од истиот автор

Neo4j:




PostgreSQL:



Разлика: - 180 ms

3. Блоговите напишани од некој автор кои содржат линк кон пост од истиот автор, кој има барем 30 коментари.

Neo4j:



PostgreSQL:




Разлика: 232 ms

4. Број на низи од 4 поста поврзани со линкови

Neo4j:



PostgreSQL:




Разлика: 437 мс

5. Број на автори кои имаат напишано и techcrunch и обичен пост

Neo4j:



PostgreSQL:



Разлика: -6 699 мс, 240 мс.

6. Автори кои си коментирале на свој пост на истиот ден кога го напишале

Neo4j:



PostgreSQL:



Разлика: 605 мс

7. Постови кои се линкуваат меѓусебно

Neo4j:

```
1 MATCH(p:Post)-[:links *2]→(p)
2 RETURN p.title

p.title

p.title

"Six New Years Resolutions For Apple And The iPhone In 2010"


Text

Code

"The Apple Tablet: Will It Be Called iSlate, iGuide, Or Something Else?"

Started streaming 2 records after 1 ms and completed after 260 ms.
```


PostgreSQL:




Разлика 28 мс

8. Постови кои во содржината го содржат името на авторот

Neo4j:




PostgreSQL:




Разлика: -106 мс

9. Автори кои имат повеќе од 1000 коментари на сите постови вкупно, во опаѓачки редослед

Neo4j:



PostgreSQL:




Разлика: 2 593 мс

10. Блогери и вкупни коментари на сите нивни постови во опаѓачки редослед

Neo4j:



PostgreSQL:



Разлика: 1 512 мс

Заклучок:

За поголемиот дел од прашалниците важи дека Neo4j побрзо дава резултат, иако има и исклучоци.

Neo4j е впечатливо побрза во случајот 9 и 10, или случаите каде што во Neo4j се избегнува употреба на вгнездено квери.

Од 2. и 3. Може да се забележи дека додавањето на дополнителни лабели на ентитетите во Neo4j може значително да ги забрза кверињата, додека во релациона база нема таква можност.

Во 4 Neo4j повторно има подобри резултати и многу поедноставен начин на пишување на квери, отколку во PostgreSQL каде треба да се направат повеќе спојувања на табели.

Во 1 и 8 се работи за квериња кои се концентрираат на една табела, и нема голема разлика во перформансите во двете бази.

Во повеќето квериња каде има поврзување помеѓу различни табели Neo4j има подобри резутати, иако нема премногу голема разлика.

Од 2 и 5 може да се забележи дека кверињата во кои се работи за различни ентитети со иста лабела кои се во ист тип на релација со некој ентитет со различна лабела имаат многу полоши перформанси. Но, промена на формата на кварито може да ја промени брзината на извршување многу пати.

Кога пак се работи за за прашалници каде се кверираат ентитети од ист тип поврзани со истата релација, Neo4j има подобри перформанси(7 и 4).

Како и да е, прашалниот јазик на Neo4, Cypher има многу полесна синтакса за користење.

Од овој експеримент може да се заклучи дека Neo4j има подобри перформанси кога пребарувањето во базата се врши на база на релации, но потребно е да се внимава каков тип на прашалници се најчести.